

Análise da Variação Altimétrica das Rotas do Transporte Coletivo de Curitiba e Suas Implicações

Felipe Snitynski Camillo¹

¹Departamento Acadêmico de Informática – Universidade Tecnológica Federal do Paraná (UTFPR)
Caixa Postal 15.064 – 91.501-970 – Curitiba – PR – Brazil

felipesnitynski@alunos.utfpr.br, nadiap@utfpr.edu.br

Abstract. This paper addresses the challenge of accurately quantifying the altimetric variation of public transport routes in Curitiba, a critical factor influencing operational costs, energy efficiency, and vehicle wear. Standard methods for assigning elevation data to route points from vector contour lines, such as nearest neighbor analysis, often yield inaccurate results. This study proposes and details a custom spatial algorithm to overcome these limitations. The method is based on a vector interpolation approach that, for each point along a bus route, identifies the two most relevant, topographically opposite contour lines and calculates a precise altitude using Inverse Distance Weighting (IDW). The algorithm was applied to the routes of Curitiba's Integrated Transport Network (RIT), and a case study on the Ligeirão Boqueirão line demonstrated the method's efficacy, revealing a total elevation change of 176 meters in a single direction. This work provides a robust methodological foundation for future analyses of energy consumption, fleet maintenance, and accessibility in urban transport systems with varied topography.

Resumo. Este artigo aborda o desafio de quantificar com precisão a variação altimétrica das rotas do transporte coletivo de Curitiba, um fator crítico que influencia custos operacionais, eficiência energética e o desgaste de veículos. Métodos convencionais para atribuir dados de elevação a pontos de rotas a partir de curvas de nível vetoriais, como a análise de vizinho mais próximo, frequentemente produzem resultados imprecisos. Este estudo propõe e detalha um algoritmo espacial customizado para superar tais limitações. O método baseia-se em uma abordagem de interpolação vetorial que, para cada ponto de uma rota de ônibus, identifica as duas curvas de nível topograficamente opostas mais relevantes e calcula uma altitude precisa por meio de Ponderação Inversa pela Distância (IDW). O algoritmo foi aplicado às rotas da Rede Integrada de Transporte (RIT), e um estudo de caso na linha Ligeirão Boqueirão demonstrou a eficácia do método, revelando uma variação total de 176 metros em um único sentido. Este trabalho oferece uma base metodológica robusta para futuras análises sobre consumo de energia, manutenção de frotas e acessibilidade em sistemas de transporte urbano com topografia variada.

1. Introdução

Desde a adoção do Plano diretor proposto por Jaime Lerner em 1968, Curitiba consolidou-se como modelo de planejamento urbano inovador, implementando a Rede Integrada de

Transporte (RIT) – primeira aplicação em larga escala do conceito de Bus Rapid Transit (BRT) – cujo primeiro corredor exclusivo de ônibus foi inaugurado em 1974 e orientou o desenvolvimento da cidade segundo eixos estruturais. Paralelamente, Curitiba tem intensificado iniciativas de Smart City, reunindo instituições acadêmicas e setor privado em consórcios para o desenvolvimento de soluções tecnológicas aplicadas à mobilidade sustentável, eficiência energética e gestão de infraestrutura crítica, com base em plataformas de dados abertos e sensoriamento remoto. Relatórios sobre inovações urbanas ressaltam a integração entre políticas públicas, participação social e tecnologia como elemento-chave para a evolução contínua da cidade e melhoria da qualidade de vida dos cidadãos. Estudos recentes também investigam as implicações socioespaciais de projetos de desenvolvimento orientado ao transporte (TOD) em Curitiba, enfatizando a necessidade de equilibrar crescimento urbano, acessibilidade e justiça social para evitar desigualdades territoriais entre diferentes regiões da cidade.

O avanço dos sistemas de transporte inteligente e de Internet das Coisas (IoT) tem gerado um volume crescente de dados operacionais, incluindo registros de GPS de veículos, informações de pagamentos eletrônicos e georreferenciamento de estações e paradas em tempo real. Esses dados permitem a aplicação de técnicas de Análise Exploratória de Dados (Exploratory Data Analysis – EDA), apoiadas por ferramentas de GIS, para identificar padrões de demanda, fluxos de passageiros e gargalos operacionais na RIT de Curitiba. Abordagens complementares de mineração de dados e aprendizado de máquina para detecção de anomalias e melhoria do serviço também vêm sendo exploradas em estudos sobre IoT aplicada a sistemas de transporte público urbano.

1.1. Objetivo Geral

Analisar e quantificar a variação altimétrica de uma rota de ônibus de Curitiba.

1.2. Objetivos específicos

Investigar:

1. Como obter e organizar os dados do transporte coletivo de Curitiba dentro de um banco de dados relacional
2. Como definir os parâmetros para localizar as linhas que mais sofrem variações de altimetria em curitiba
3. Como definir quais abordagens de SIGs se adequam melhor ao problema

Obter:

1. A variação de altimetria de uma linha de ônibus

1.3. Justificativa

A Rede Integrada de Transporte (RIT) de Curitiba é reconhecida internacionalmente por sua eficiência e capacidade de integração. No entanto, a complexidade e a extensão do sistema, aliadas à diversidade topográfica da cidade, apresentam desafios contínuos para a otimização operacional e a melhoria da experiência do usuário. Enquanto estudos anteriores frequentemente se concentram em aspectos como fluxo de passageiros, integração tarifária e expansão da rede, a influência detalhada da variação altimétrica nas rotas de ônibus permanece uma área com potencial significativo de investigação.

Este estudo, ao se propor a identificar e analisar rotas de ônibus que mais sofrem variação de altimetria em Curitiba, justifica-se pela necessidade de aprofundar o conhecimento sobre fatores geográficos que impactam diretamente diversos aspectos do sistema de transporte coletivo:

1. Eficiência Energética e Custos Operacionais: A topografia accidentada, com aclives e declives acentuados, impõe um maior esforço aos veículos. Rotas com grande variação altimétrica tendem a apresentar um consumo de combustível (para ônibus a diesel) ou energia (para ônibus elétricos) significativamente superior em comparação com rotas predominantemente planas. Adicionalmente, componentes mecânicos como motor, transmissão e, crucialmente, sistemas de freios, sofrem maior desgaste, elevando a frequência de manutenção e os custos operacionais. A identificação precisa dessas rotas permite um planejamento de frota mais estratégico, a alocação de veículos mais adequados para cada perfil de rota e uma estimativa mais acurada dos custos de operação e manutenção.

2. Fundamentação Teórica

Diversos estudos documentam a evolução do sistema BRT de Curitiba desde sua concepção na década de 1970, destacando sua eficiência operacional e inovações de planejamento urbano [Kozievitch et al. 2016]. A partir de 2009, a cidade implementou medidas de modernização como a introdução de linhas temáticas e uso de biodiesel, visando à redução de emissões e à melhoria da experiência do usuário [Duarte et al. 2016].

Estudos de análise exploratória de dados aplicados ao transporte público de Curitiba utilizaram ferramentas GIS e técnicas estatísticas para revelar padrões de demanda e gargalos operacionais. Kozievitch et al. discutem descoberta de padrões, integração de dados e abertura de dados para a comunidade acadêmica [Kozievitch et al. 2016]. Em complemento, abordagens de mineração de dados para detecção de anomalias em sistemas IoT foram propostas por Fong et al. para veículos inteligentes [Fong et al. 2018].

Pesquisas recentes também investigam a complementaridade entre o BRT e serviços de ridesharing para cobertura de first-/last-mile, avaliando milhões de pontos de localização de passageiros [Utsch et al. 2019]. Finalmente, estudos de planejamento orientado ao transporte (TOD) em Curitiba têm sido avaliados quanto às suas implicações socioespaciais [Silva et al. 2020].

2.1. A Cidade como um organismo vivo

Antes de pensarmos na cidade como um organismo vivo, vale entender o termo “organismo”. Ele vem do grego organon, que significa “instrumento” ou “órgão” e reforça a ideia de partes coordenadas para um mesmo propósito. Um organismo vivo é, portanto, um sistema complexo cujas diversas estruturas trabalham em conjunto para garantir sua sobrevivência.

De modo análogo, uma cidade — por mais planejada e organizada que seja — também é formada por inúmeros elementos interdependentes. Cada componente físico (ruas, edifícios, praças) e cada indivíduo que a habita carrega múltiplas camadas sociais, culturais e funcionais. Todas essas partes, assim como em um organismo biológico, interagem entre si para manter a vida urbana viva.

3. Metodología

3.1. Dados usados para calcular altimetria

Nessa seção serão abordadas os dados usados no trabalho.

3.1.1. Tabela rotas de Onibus

A tabela usada para saber as rotas de ônibus foi extraída da API webservice da URBS, a tabela foi extraída com SRID 4326 - comum para visualização, os dados são estruturados da seguinte forma:

Table 1. Descrição das Colunas do Conjunto de Dados de Shapes de Ônibus

Nome da Coluna	Tipo de Dado (Pandas)	Descrição
SHP	int64	Identificador do traçado (shape) da rota.
Latitude	float64	Coordenada de latitude do ponto na rota.
Longitude	float64	Coordenada de longitude do ponto na rota.
COD	int64	Código relacionado à linha ou tipo de via.

Uma rota de ônibus é formada por vários pontos que juntos formam a rota de ônibus. Figura 1 mostra um recorte dos pontos que juntos compõem uma rota de ônibus.



Figure 1. Imagem de um trecho da rota contendo os pontos que formam a linha

A Figura 2 é a imagem de toda a linha, os múltiplos pontos formam a linha.

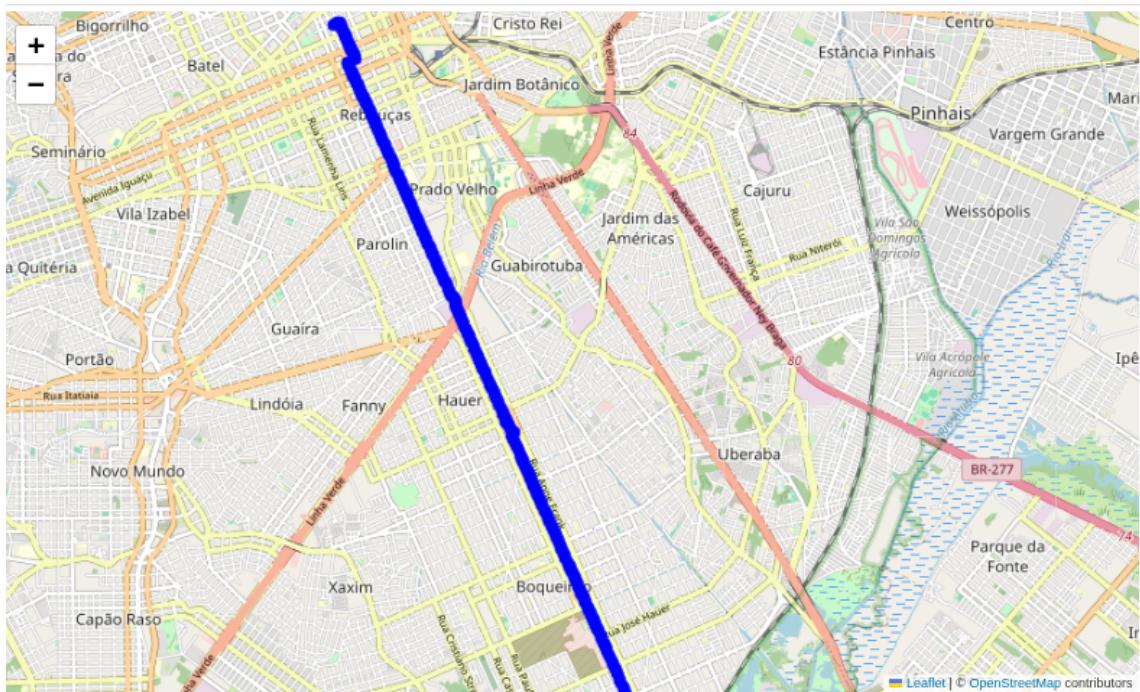


Figure 2. Imagem de uma da rota contendo os pontos que formam a linha

3.1.2. Tabela altimetria

A Tabela apresenta a estrutura dos dados espaciais referentes às curvas de nível utilizadas neste estudo. Cada registro representa um segmento linear de uma curva de nível, descrito por diversos atributos temáticos e geométricos. O campo gid corresponde a um identificador único atribuído a cada feição. O atributo layer define o tipo da curva, sendo que, neste conjunto de dados, predominam curvas intermediárias.

O campo elevation indica a elevação altimétrica do segmento, expressa em metros. As informações sobre o levantamento aerofotogramétrico e sua restituição cartográfica estão representadas pelas colunas datavoo e datarest, respectivamente. O atributo resptec especifica a empresa ou entidade responsável pelo mapeamento.

A coluna escala refere-se à escala cartográfica adotada durante o levantamento, enquanto curvas informa o intervalo altimétrico entre curvas consecutivas. Já o atributo shapelen representa o comprimento total do segmento linear, em metros. Por fim, a geometria de cada feição está codificada no campo geom, no formato binário (WKB), o que permite a representação precisa da localização espacial das curvas.

Table 2. Descrição das Colunas do Conjunto de Dados das Curvas de Nível

Nome da Coluna	Tipo de Dado (Pandas)	Descrição
gid	int64	Identificador único do segmento de curva
layer	object	Tipo de curva (ex.: CURVA INTERMEDIARIA)
elevation	float64	Elevação em metros
data_voo	object	Data do voo aerofotogramétrico
data_rest	object	Data da restituição cartográfica
resp_tec	object	Responsável técnico pela cartografia
escala	object	Escala do levantamento (ex.: 1:2.000)
curvas_m	float64	Distância entre curvas em metros
shape_len	float64	Comprimento do segmento em metros

3.1.3. Desafios na Atribuição de Dados Altimétricos

A principal dificuldade metodológica do estudo consistiu em associar de forma precisa a altitude de cada ponto (vértice) que compõe o traçado das rotas de ônibus com os dados de altimetria, que se apresentam como curvas de nível (vetores do tipo `LINESTRING`). O que exigiu a implementação de uma estratégia de atribuição de altitude baseada em algoritmos disponíveis. Nesse processo, duas abordagens iniciais foram consideradas e descartadas devido a limitações intrínsecas.

Abordagem 1: Poligonização das Curvas de Nível A primeira tentativa consistiu em converter as linhas de curvas de nível em polígonos. A intenção era que cada polígono representasse uma faixa de altitude, permitindo uma simples operação de junção espacial (*spatial join*) para atribuir a elevação a cada ponto da rota contido dentro de um polígono. Contudo, esta abordagem mostrou-se inviável. Das mais de 140.000 linhas de curvas de nível, apenas um percentual baixo (aproximadamente 7%) formava polígonos fechados. A grande maioria das curvas são, por natureza, linhas abertas que se estendem até as bordas da área de mapeamento, impossibilitando a criação de uma cobertura poligonal completa e confiável.

Abordagem 2: Análise de Vizinho Mais Próximo A segunda alternativa seria atribuir a cada ponto da rota a elevação da curva de nível mais próxima, utilizando uma análise de vizinho mais próximo (*nearest neighbor*). Embora computacionalmente simples, este método introduziria erros significativos de quantização. Por exemplo, um ponto localizado a 4 metros de uma curva de 910m e a 6 metros de uma curva de 920m seria incorretamente associado à altitude de 910m. Esse processo geraria um perfil de elevação artificial "em degraus", que não reflete a variação contínua e gradual do terreno, comprometendo fundamentalmente a precisão do cálculo da variação altimétrica acumulada. A Figura 3 mostra os ponto e as curvas de níveis mais próximas.

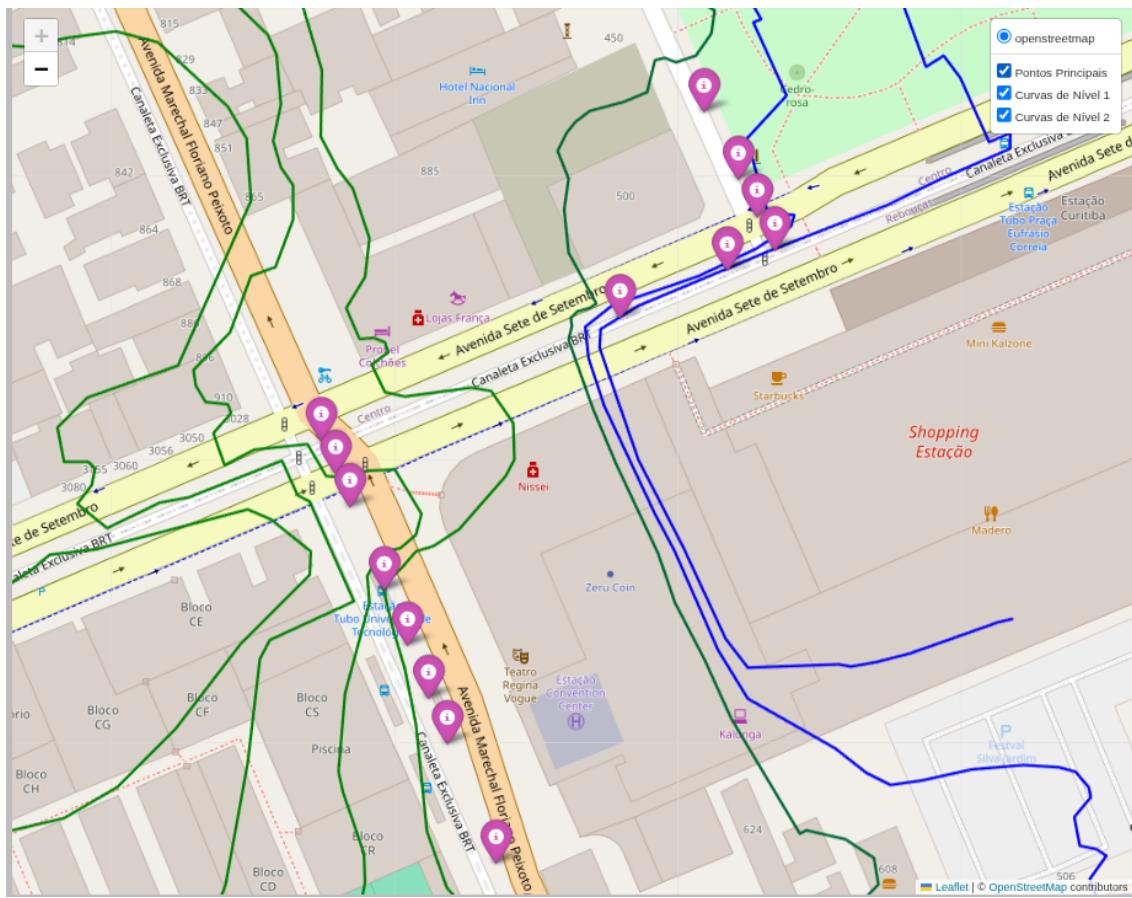


Figure 3. Imagem de um trecho da rota contendo os pontos que formam a linha e as curvas de níveis

A Figura 4 mostra todos os pontos e as curvas de níveis mais próximas.

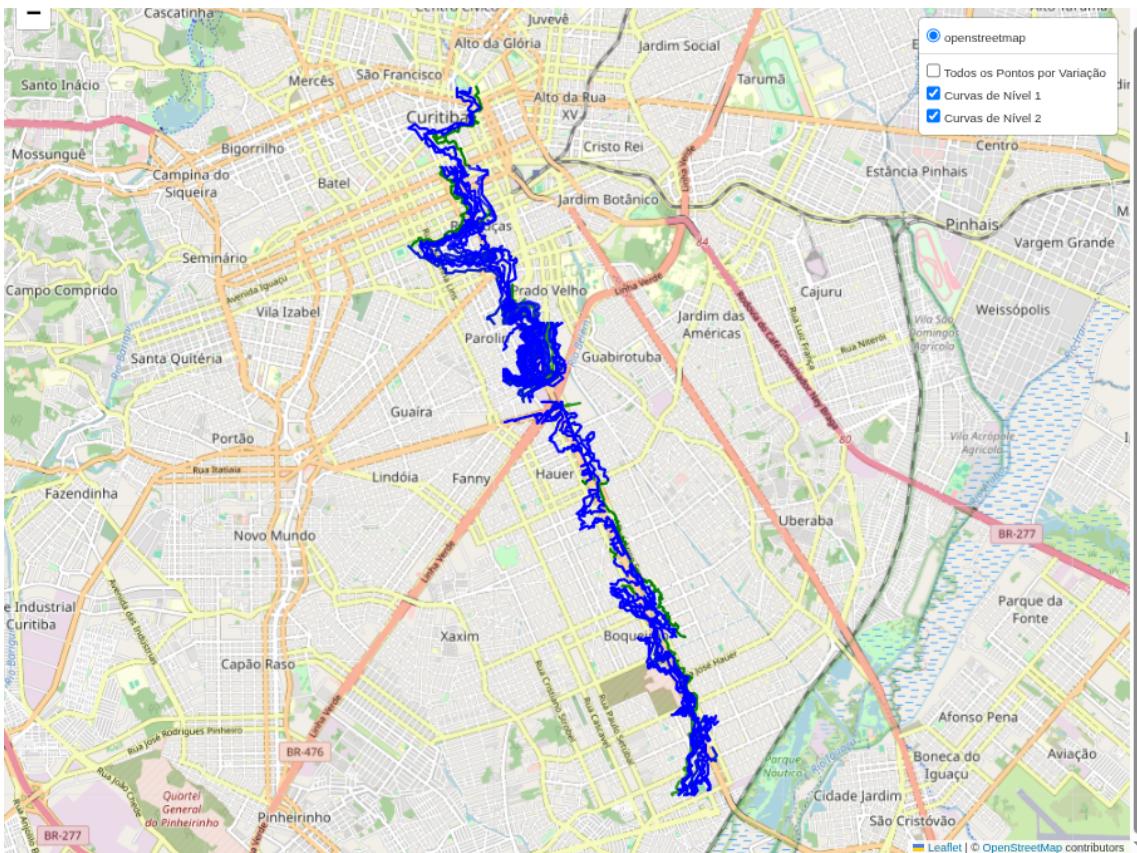


Figure 4. Imagem das curvas de níveis associadas a algum ponto

Solução Adotada: Interpolação Vetorial Diante das limitações das abordagens mais diretas, tornou-se evidente a necessidade de um método mais robusto que pudesse **interpolar** a altitude de um ponto com base em sua posição relativa entre curvas de nível adjacentes. Portanto, a solução foi desenvolver um algoritmo customizado, detalhado na Seção 3.1.4, que:

1. Identifica, para cada ponto da rota, a curva de nível mais próxima (C_1).
2. Localiza a curva de nível oposta (C_2) em relação ao ponto, garantindo que o ponto esteja topograficamente entre elas.
3. Calcula a altitude do ponto por meio de uma interpolação linear ponderada pela distância inversa a essas duas curvas.

Esta abordagem, embora mais complexa, garante uma representação muito mais fiel e contínua do relevo percorrido pelas rotas de ônibus.

Seleção da Curva Oposta por Análise Vetorial Para garantir uma interpolação altimétrica coerente, não basta encontrar a curva de nível mais próxima (C_1); é crucial identificar uma segunda curva (C_2) que esteja topograficamente oposta ao ponto da rota (P_i). A determinação dessa oposição é realizada por meio de análise vetorial, uma abordagem padrão em geometria computacional para resolver questões de orientação e posicionamento relativo. O método consiste em avaliar o alinhamento entre o vetor do ponto em C_1 para P_i e o vetor de P_i para o ponto candidato em C_2 . A utilização do produto

escalar entre esses vetores permite selecionar a curva que garante que P_i esteja geometricamente posicionado entre C_1 e C_2 , evitando interpolações erradas e garantindo a validade topológica do cálculo.

3.1.4. Algoritmo para Associação de Dados Altimétricos a Rotas de Ônibus

Para integração dos dados altimétricos às rotas de ônibus, foi desenvolvido um algoritmo espacial composto pelas seguintes etapas:

1. **Reprojeção cartográfica:** Ambas as camadas (curvas de nível e rotas) foram re-projetadas para o sistema de referência SIRGAS 2000 (EPSG:31982), garantindo operações métricas precisas.
2. **Indexação espacial:** Foi construída uma estrutura de dados *STR-tree* sobre as geometrias das curvas de nível, otimizando consultas de proximidade espacial.
3. **Identificação de curvas adjacentes:** Para cada vértice P_i da rota:
 - Localiza-se a curva de nível C_1 mais próxima utilizando consulta direta à árvore espacial
 - Aplica-se um *buffer* de 50m centrado em P_i para identificar curvas candidatas
 - Determina-se a curva C_2 topograficamente oposta através de análise vetorial:

$$\vec{V}_b = P_i - C_{1\text{ponto,prox}}, \quad \vec{V}_c = C_{2\text{ponto,prox}} - C_{1\text{ponto,prox}} \quad (1)$$

$$\text{oposição} = \left| \vec{V}_b \times \vec{V}_c \right| > \epsilon \quad (\epsilon = 10^{-8}) \quad (2)$$

4. **Interpolação altimétrica:** A altitude Z_{P_i} é calculada por interpolação linear ponderada inversa:

$$Z_{P_i} = \frac{\frac{Z_{C_1}}{d(P_i, C_1)} + \frac{Z_{C_2}}{d(P_i, C_2)}}{\frac{1}{d(P_i, C_1)} + \frac{1}{d(P_i, C_2)}} \quad (3)$$

onde d representa a distância euclidiana.

5. **Cálculo de variação altimétrica:** A variação entre vértices consecutivos, para se obter a variação altimétrica de uma rota de ônibus, é computada como:

$$\Delta Z_i = |Z_{P_{i+1}} - Z_{P_i}| \quad (4)$$

Algorithm 1 Associação Altimétrica com Interpolação IDW

Require: G_{rotas} , G_{curvas}

Ensure: ΔZ_{rota} , altimetria interpolada para cada ponto

```
1: Reprojetar geometrias para EPSG:31982
2: Construir STR-tree para as curvas de nível em  $G_{\text{curvas}}$ 
3: for cada ponto  $P_i$  em  $G_{\text{rotas}}$  do
4:    $C_1 \leftarrow$  curva mais próxima de  $P_i$  usando STR-tree ( $k = 1$ )
5:    $C_{\text{cand}} \leftarrow$  curvas dentro de um buffer de 50m de  $P_i$ 
6:   Ordenar  $C_{\text{cand}}$  por distância a  $P_i$ 
7:   for cada  $C_j$  em  $C_{\text{cand}}$  do
8:     if  $C_j$  está topograficamente oposta a  $C_1$  then
9:        $C_2 \leftarrow C_j$ 
10:      break
11:    end if
12:   end for
13:   if  $Z_{C_1}$  e  $Z_{C_2}$  são válidos then
14:     Calcular  $d_1 \leftarrow$  distância( $P_i, C_1$ )
15:     Calcular  $d_2 \leftarrow$  distância( $P_i, C_2$ )
16:     if  $d_1 = d_2 = 0$  then
17:        $Z_{P_i} \leftarrow \frac{Z_{C_1} + Z_{C_2}}{2}$ 
18:     else if  $d_1 = 0$  then
19:        $Z_{P_i} \leftarrow Z_{C_1}$ 
20:     else if  $d_2 = 0$  then
21:        $Z_{P_i} \leftarrow Z_{C_2}$ 
22:     else
23:        $w_1 \leftarrow 1/d_1, w_2 \leftarrow 1/d_2$ 
24:        $Z_{P_i} \leftarrow \frac{Z_{C_1} \cdot w_1 + Z_{C_2} \cdot w_2}{w_1 + w_2}$ 
25:     end if
26:   else if apenas um dos valores está disponível then
27:     Usar o valor de elevação disponível
28:   else
29:      $Z_{P_i} \leftarrow \text{NaN}$ 
30:   end if
31: end for
32: for  $i \leftarrow 1$  até  $n_{\text{pontos}} - 1$  do
33:    $\Delta Z_i \leftarrow |Z_{P_{i+1}} - Z_{P_i}|$ 
34: end for
```

4. Resultados

A partir das discussões nos capítulos anteriores foi possível cruzar as camadas de rotas de transporte coletivo e altimetria de Curitiba para obtermos a variação de altimetria ao longo de uma rota de ônibus. A Figura 4 mostra o cálculo de variação de altimetria para a rota Ligeirão Boqueirão, a qual foi de 176 metros em apenas um sentido, ou seja, saindo do terminal do boqueirão e indo para o centro.

```
[14]: # Calcular as diferenças absolutas da coluna elevation entre pontos consecutivos
resultado_copia['diff_elev'] = resultado_copia['altimetria_interpolada'].diff().abs()

# Somar todas as diferenças para obter a variação total altimétrica
variacao_total = resultado_copia['diff_elev'].sum()

print("Variação para linha 500 em metros: ", variacao_total)

Variação para linha 500 em metros: 176.6362814867581
```

Figure 5. Trecho do código que obtém a diferença de altimetria na rota

A figura Figura 6 mostra a variação altimétrica em um trecho da linha de ônibus, é possível visualizar o ponto, altimetria e as curvas de nível associadas a ele.

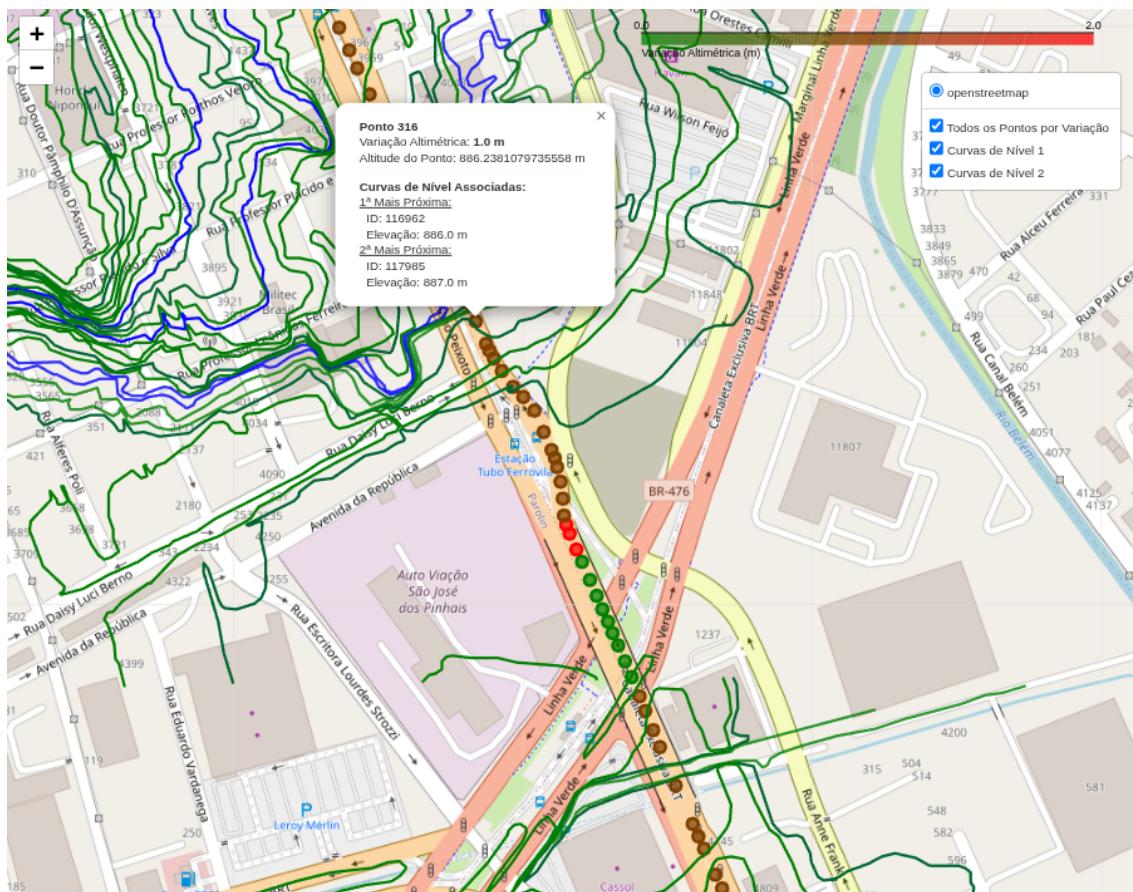


Figure 6. Imagem de um trecho da rota contendo os pontos que formam a linha e as curvas de níveis

A Figura 7 mostra a altimetria de todos os pontos da rota.

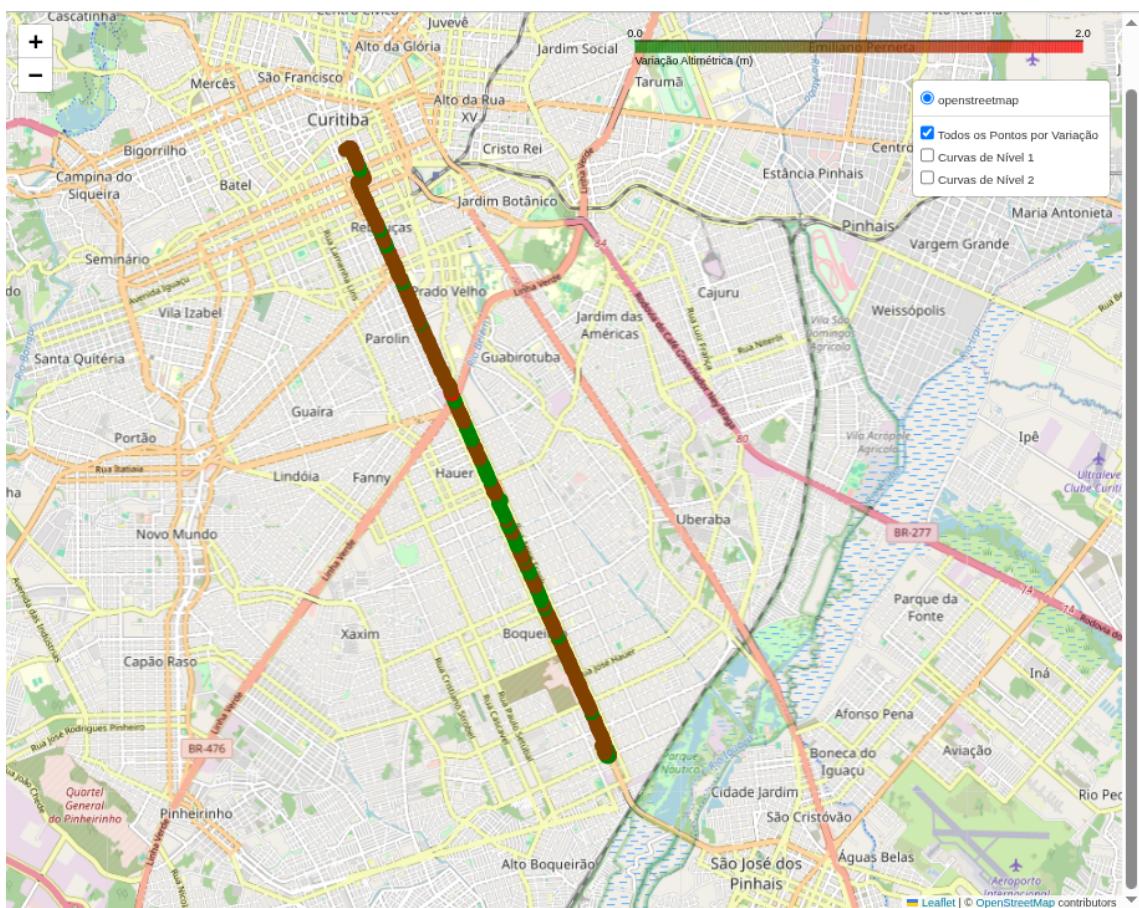


Figure 7. Imagem de um trecho da rota contendo os pontos que formam a linha e as curvas de níveis

4.1. Trabalhos futuros

Para futuros trabalhos, deixo como sugestões:

1. Aplicar uma camada extra contendo a localização dos pontos de ônibus, assim é possível determinar a altimetria entre pontos de desembarque e embarque consecutivos de uma linha
2. Aplicar uma camada de velocidade média dos ônibus nos trechos de maior variação altimétrica de um ônibus para avaliar a possível correlação entre atraso e rotas com muitas subidas e descidas
3. Aplicar uma camada que contenha os equipamentos de acessibilidade, avaliar por exemplo pontos que estejam em subidas/descidas os quais podem dificultar desembarque de pessoas com

References

- Duarte, M. C., Silva, A. F., and Souza, R. L. (2016). Mobility open data: Use case for curitiba and new york. In *XXVIII Simpósio Brasileiro de Sistemas de Informação*, pages 112–123, São Paulo, SP, Brazil.
- Fong, L., Chen, W., and Zhang, X. (2018). Anomaly detection framework for intelligent public transport vehicles. *Journal of Transport and Data Science*, 5(2):45–59.

- Kozievitch, N. P., Gadda, T. M. C., Fonseca, K. V. O., Rosa, M. O., Gomes, L. C., and Akbar, M. (2016). Exploratory analysis of public transportation data in curitiba. In *Anais do XLIII Seminário Integrado de Software e Hardware*, pages 36–47, Curitiba, PR, Brazil.
- Silva, C. M., Pereira, J. R., and Almeida, T. F. (2020). Socio-spatial implications of tod in curitiba’s brt corridors. In *Proceedings of the 12th International Conference on Urban Planning*, pages 78–89, Brasília, DF, Brazil.
- Utsch, D., Müller, J., and Becker, K. (2019). Integrating ridesharing with brt for first-/last-mile coverage. *Transportation Research Record*, 2673(4):250–261.